

GEMİ TESPİTİ UYGULAMASINDA YOLOV8 VE YOLOV9 ALGORİTMALARININ PERFORMANS DEĞERLENDİRMESİ

Özet

- Bu çalışma, YOLOv8 ve YOLOv9 mimarilerini kullanarak uzaktan algılama ile gemi tespiti yapmayı amaçlamaktadır .
- Çalışma, gemi tespiti ve sınıflandırmasının deniz gözetimi ve izleme alanındaki önemini vurgulamaktadır .
- "Ships in Google Earth" veri seti kullanılarak YOLOv8 ve YOLOv9 mimarilerinin performansı karşılaştırılmıştır .

Giriş

- Gemi tespiti, balıkçılık yönetimi, gemi trafiği hizmeti, liman yönetimi ve deniz savaşının gerçekleştirilmesinde temel bir konudur .
- Uzaktan algılama teknolojileri, yüksek zamanlılık, geniş kapsama alanı ve düşük maliyetli erişilebilirlik sunması nedeni ile gemilerin izlenmesi için birincil yöntem olarak ortaya çıkmıştır .
- Gemi tespiti çalışmalarında karmaşık deniz ortamları, yetersiz ayırt edici özellikler, büyük ölçekli varyasyonlar, yoğun ve döndürülmüş dağılımlar, büyük en boy oranları ve pozitif ve negatif örnekler arasındaki dengesizlikler zorluklar olarak belirlenmektedir .

Materyal ve Metot

- YOLO mimarileri; omurga (Backbone), boyun (Neck) ve baş (Head) bölümlerinden oluşmaktadır .
- YOLOv8, mimari, kayıp fonksiyonları ve segmentasyon yeteneklerindeki ilerlemeleriyle çeşitli uygulamalar için güçlü bir araç olarak öne çıkmaktadır .
- "Ships in Google Earth" veri seti, toplamda 1658 görüntüden oluşmaktadır ve uydu çekimi gemi görüntülerini içermektedir .

Araştırma Bulguları

- YOLOv8 ve YOLOv9 modelleri, kesinlik, duyarlılık ve ortalama hassasiyet (mAP) metriklerine göre karşılaştırılmıştır .
- YOLOv9'un eğitim kayıpları başlangıçta daha hızlı bir düşüş göstermektedir, bu da modelin daha hızlı yakınsadığını işaret etmektedir .
- YOLOv9, YOLOv8'e kıyasla daha yüksek mAP değerlerine ulaşmakta (özellikle başlangıç iterasyonlarında) bu durum genel tespit performansının daha iyi olduğunu göstermektedir .

Tartışma ve Sonuç

- YOLOv9, genel olarak mAP ve duyarlılık açısından YOLOv8'e göre biraz daha iyi performans sergilemektedir .
- YOLOv9'un gelişmeleri özellikle erken iterasyonlarda belirgin, bu da modelin daha hızlı yakınsadığını işaret etmektedir .
- Her iki model de gemi tespiti için etkili çözümler sunmaktadır .

Kaynaklar

- Literatürdeki çalışmalar, YOLO mimarilerinin farklı türdeki veri setleri üzerinde de başarılı sonuçlar elde ettiğini göstermektedir .
- Gelecekteki çalışmalarda, sadece gemi türleri değil, deniz araçlarının birçoğunu kapsayacak bir veri seti ile çalışılması planlanmaktadır .
- YOLO mimarilerinin gelişimi ile en güncel YOLO mimarilerinin kullanımı gelecekteki çalışmalarında başarılı sonuçlarla yapılabileceğine imkân tanıyacaktır .

Mask R-CNN İle Uydu Görüntülerinde Gemi Tespiti

Öz

- Derin öğrenme alanındaki gelişmeler, uzaktan algılama görüntülerinde gemi tespitinde önemli ilerlemeler sağlamıştır .
- Konvolüsyonel sinir ağları (CNN), nesne tespiti ve sınıflandırması için geliştirilmiş olup, gemi tespitinde yaygın olarak kullanılmaktadır .
- Bu çalışma, Mask R-CNN yöntemini kullanarak uydu görüntülerindeki gemileri tespit etmeyi ve modelin performansını değerlendirmeyi amaçlamaktadır .

Giriş

- Uzaktan algılama görüntülerinde gemi tespiti, deniz güvenliği, yönetimi ve taşımacılığı gibi birçok alanda önemlidir .
- Yüksek çözünürlüklü uydu görüntülerinin kullanımı, gemilerin otomatik olarak çıkarılmasını sağlamıştır .
- Makine öğrenimi tabanlı obje tespit modelleri, daha hızlı ve doğru sonuçlar üretmektedir .

Materyal ve Yöntem

- Çalışmada Google Earth tarafından sağlanan 1 metre mekânsal çözünürlüklü RGB uydu görüntüleri kullanılmıştır .
- Toplam 1838 görüntü kullanılarak eğitim, validasyon ve test veri setleri oluşturulmuştur .
- Görüntülerdeki 3279 gemi bir GIS yazılımı kullanılarak sayısallaştırılmıştır .

Yöntem

- Uydu görüntülerindeki gemileri tespit etmek üzere Mask R-CNN modeli kullanılmıştır .
- Mask R-CNN çıktı olarak gemilerin maskelerini, sınırlayıcı kutularını ve olasılık değerlerini üretmektedir .
- Mask R-CNN dört modülden oluşmaktadır: özellik çıkarım ağı, bölge öneri ağı, öneri işleme modülü ve bölge-tabanlı konvolüsyonel sinir ağı (R-CNN) .
- FPN'nin ilk aşaması olan aşağıdan yukarıya yolda, 5 ayrı blokta özellik özellik haritası (Ci) üretilmektedir .
- Süreçte bir sonraki aşama, oluşturulan özellik haritalarının Bölge Öneri Ağında (RPN) işlenmesidir .

- Mask R-CNN’de FPN’de üretilmiş farklı ölçeklerdeki özellik haritaları kümesi {P2, P3, P4 ve P5} Bölge Öneri Ağı (RPN) modülüne girilmektedir .
- Modelin RPN modülünde ayrıca, üretilen önerilerin nesne olup olmadığına dair bir güven eşiği tanımlıdır .
- Mask R-CNN’nin son modülünde tam-bağlantılı katmanlar yer almaktadır .
- Mask R-CNN modelindeki son işlem adımı bölge-temelli konvolüsyonel sinir ağıdır (R-CNN) .

Model Eğitimi

- Bu çalışmada Mask R-CNN modeli için Waleed’in (2017) Tensorflow ve Keras derin öğrenme çerçevelerinde çalışan GitHub uyarlaması kullanılmıştır .
- Modelde omurga ağ olarak Common Objects in Context (COCO) veri setiyle ön-eğitim almış ResNet-101 kullanılmıştır .
- Model, başlangıç değeri 0,001 olan öğrenme oranı kullanılarak toplam 80 bin iterasyonda eğitilmiştir .

Tespit Değerlendirme Metrikleri

- Modelin tespit performansını değerlendirmek için kesinlik, geri getirme ve F1-skoru metrikleri kullanılmıştır .
- Kesinlik, doğru tahminlerin toplam tahminler içerisindeki oranını göstermektedir .
- Geri getirme ise yapılan tespitlerdeki doğru pozitiflerin toplam yer doğruluklarına oranıdır .

Bulgular ve Tartışma

- Model için en uygun güven eşiğinin 0,5 olduğu bulunmuştur .
- Test verisi için modelin geri getirmesi 0,9238; kesinliği 0,9058; F1-skoru ise 0,9148 olmuştur .
- Model özellikle birbirine yakın konumlanmış gemilerin tespitinde zorlanmaktadır .
- Şekil 5.a’da 1 numaralı daire ile gösterilen kara parçasını hatalı şekilde gemi olarak sınıflandırmış, 2 numaralı daire içerisinde gösterilen, yan yana bulunan iki gemiyi ise tek gemi olarak işaretlemiştir .
- Rotterdam’daki bir iç limanda bulunan gemileri içeren bir uydu görüntüsünün yer aldığı Şekil 6.a’da ise dokuz gemi bulunmaktadır .
- Model bu gemilerden yedisini doğru tespit etmiş ikisini ise gözden kaçırmıştır .
- Yukarıda ifade edilen, birbirine yakın konumlanmış gemiler için üretilen tespitlerdeki yanlış sayısının fazlalığı Faster R-CNN gibi bölge-tabanlı nesne tespit algoritmalarının kullanıldığı diğer araştırmalarda da söz konusudur .
- Bu problemin RPN’de öneriler için kullanılan dik sınırlayıcı kutulardan kaynaklandığı ifade edilmektedir .
- Bu sorunun çözümüne yönelik olarak RPN’de dönük sınırlayıcı kutuların kullanımı önerilmiştir .

Sonuç

- Mask R-CNN yöntemiyle uydu görüntülerindeki gemiler tespit edilmiş ve performansı değerlendirilmiştir .
- 0,5'lik bir güven eşiği ile çalıştırılan Mask R-CNN modeli test görüntülerinde yer alan 604 geminin 558'ini doğru şekilde tespit etmiş ve 58 yanlış alarm üretmiştir .
- Modelin çeşitli görüntüler için ürettiği tespitler incelendiğinde, özellikle birbirine yakın konumlanmış gemiler söz konusu olduğunda ya hepsinin tek bir gemi olarak işaretlendiği ya da gemilerden birinin veya birkaçının gözden kaçırıldığı görülmektedir .

Gelişmiş Deniz Gözlemi: SAR Tabanlı Gemi Tespiti için CNN Algoritmalarının Kullanımı

1. Giriş

Gemi tespiti, denizcilik alanında önemli bir araştırma konusudur. Bu çalışma, Sentinel-1 verileri ve Faster R-CNN algoritmaları kullanarak gemi tespiti yapmayı hedeflemektedir. Doğru gemi tespiti, deniz güvenliği, çevresel izleme ve arama kurtarma operasyonları gibi birçok uygulama için kritik öneme sahiptir

2. Yöntem

2.1. Veri Kaynağı

Sentinel-1, Avrupa Uzay Ajansı tarafından işletilen bir radar uydusudur ve yüksek çözünürlüklü SAR görüntüleri sağlar. Bu çalışma, Sentinel-1 VH verilerini kullanarak Faster R-CNN algoritması ile bir gemi tespit algoritması geliştirmiştir

2.2. Algoritma

Faster R-CNN, nesne algılama için yaygın olarak kullanılan bir derin öğrenme algoritmasıdır. Algoritma, giriş görüntülerinden nesne önerileri üretmek için bir Bölge Öneri Ağı (RPN) kullanır. Bu öneriler daha sonra sınıflandırma ve konumlandırma için bir algılama ağına aktarılır

3. Bulgular

Geliştirilen gemi tespit algoritması, Sentinel-1 VH SAR görüntülerinde %86,11 doğruluk oranı elde etmiştir. Algoritma, farklı boyut ve türdeki gemileri başarıyla tespit edebilmiş ve düşük yanlış pozitif oranları göstermiştir

4. Sonuçlar

Bu çalışma, derin öğrenme tekniklerinin ve SAR görüntülerinin gemi tespitinde etkinliğini vurgulamaktadır. Önerilen algoritmanın performansı, deniz güvenliği ve çevresel izleme gibi alanlarda potansiyel uygulamalar sunmaktadır. Ayrıca, bu çalışma, gelecekteki araştırmalar için bir zemin hazırlamaktadır.